

Специфічність тригера, а не точність корекції: дослідження негативних результатів корекції дрейфу без еталонного прогнозу для замороженої SAM2 на SA-V

Анотація

Ми досліджуємо, чи можна покращити заморожену модель сегментації відео SAM2.1 (Hierarchical-Tiny) під час інференсу, без донавчання і без доступу до істинної розмітки (ground truth), шляхом виявлення та корекції дрейфу поширення (propagation drift) — втрати або неправильного присвоєння ідентичності об'єкта під час поширення маски на основі пам'яті. На офіційному бенчмарку SA-V валідована базова політика промптингу (box_centroid) отримує J&F = 72.1 на val та 74.4 на test. Механізм корекції дрейфу на основі моделі руху ("P5"), що виявляє підозрюваний дрейф за сигналами співвідношення площ та стрибка позиції й виправляє його свіжим повторним промптом-боксом, центрованим на екстрапольованій за припущенням постійної швидкості позиції, досягає разючих результатів на попередньо відібраних за істинною розміткою підмножині з 30 об'єктів, про які достеменно відомо, що вони справді дрейфують: +15.5 процентних пункти J&F порівняно з базовою лінією без еталонного прогнозу (objscore). Однак застосований без відбору до повної, нефільтрованої популяції з 293 об'єктів на val, той самий механізм виявляється чистою шкодою: J&F падає до 68.7, що на 3.4 пункти нижче простої базової лінії, причому 178 об'єктів погіршуються проти лише 44, що покращуються. Дванадцять подальших спроб пом'якшення, що охоплюють гейтинг на рівні кадру, запобіжники на рівні об'єкта, попередній відбір на основі ознак та пом'якшення корекції, не усувають цього розриву; найкращий варіант досягає лише 0.8 пункти нижче базової лінії на val і 1.8 пункти нижче на test. Ми представляємо ці результати як діагностичне дослідження негативних результатів: точність корекції на істинно позитивних випадках не є обмежувальним фактором придатності до розгортання — ним є специфічність тригера за низької базової частоти позитивного класу. Ми розглядаємо цей висновок у контексті теорії класифікації за незбалансованих класів та літератури з адаптації під час тестування (test-time adaptation), і окреслюємо неперевірені напрямки, які мотивують ці результати, не стверджуючи, що ми їх випробували.

1. Вступ

Промптовані моделі сегментації об'єктів відео, побудовані на парадигмі Segment Anything (Kirillov et al., 2023; Ravi et al., 2024), дозволяють користувачу вказати цільовий об'єкт один раз, як правило, на першому кадрі, і поширити маску на решту відео за допомогою навченого механізму пам'яті. Ця конструкція приваблива саме тому, що потребує так мало взаємодії: Ravi et al. (2024) повідомляють,

що SAM2 потребує приблизно втричі менше взаємодій з користувачем, ніж попередні підходи до сегментації відео. Це твердження про ефективність спирається на неявне припущення — що єдиний промпт, поширений пам'яттю замороженої моделі, залишається закріпленим за правильним об'єктом протягом усього відео. Коли це не так, практичним засобом є або донавчання моделі на складніших даних, що є витратним і прив'язаним до конкретного чекпоінта, або пошук якогось способу виявлення й виправлення дрейфу під час інференсу без зміни ваг і без доступу до істинної розмітки. Другий варіант і є предметом цієї статті.

Ми працюємо з SAM2.1 Hiera-Tiny, замороженою протягом усього дослідження, оціненою на офіційному бенчмарку SA-V (Meta AI, 2024) за допомогою офіційного оцінювача J, F, J&F. Валідована базова політика промптингу, `box_centroid` — щільний обмежувальний бокс навколо істинної маски на першому анотованому кадрі плюс центроїдна точка — отримує J&F = 72.1 на SA-V val (293 об'єкти, 155 відео) і 74.4 на SA-V test (278 об'єктів, 150 відео), після перенесення з J&F-Mean = 0.8235 на повному DAVIS 2017 val. Аналіз режимів відмов на розбитті val показує, що головною причиною низьких показників об'єктів є не поганий початковий промпт: 83% об'єктів з J&F нижче 40 мали правильний старт (IoU на кадрі промпту ≥ 0.3), але деградували під час поширення. Експеримент з еталонним прогнозом (англ. oracle — маска з істинної розмітки) — повторний промпт кожного п'ятого анотованого кадру з істинної маски — відновлює цю популяцію з J&F = 26.1 до 84.3, приріст 58.2 пункти, підтверджуючи, що деградація є відновлюваною проблемою збереження пам'яті, а не перцептивним обмеженням моделі.

Питання, на яке відповідає ця стаття: чи досяжна ця межа у 58.2 пункти без істинної розмітки. Ми розробили механізм корекції дрейфу на основі моделі руху, P5, який виявляє дрейф за двома сигналами самоузгодженості (співвідношення площі маски до поточної базової лінії та стрибок позиції відносно екстраполяції траєкторії об'єкта за припущенням постійної швидкості) і виправляє його повторним промптом зі свіжим обмежувальним боксом, центрованим на екстрапольованій позиції, а не повторним впровадженням власної, можливо пошкодженої, маски моделі. На попередньо відібраний за істинною розміткою підмножині з 30 об'єктів, незалежно визначених як справжні відмови через дрейф поширення, повністю калібрований P5 досягає J&F = 42.3, приріст 15.5 пункти порівняно з базовою лінією без еталонного прогнозу, яку він замінює у розгорнутому порівнянні (27.4, найсильніша з попередніх спроб без еталонного прогнозу, на 8.5 пункти нижча за нетюнінгований результат P5) і найкращий результат основного калібрувального перебору (пізніше уточнення, описане в розділі 4.5, підвищує його ще трохи, до 42.6).

Центральний висновок статті полягає в тому, що цей результат не витримує зіткнення з невідібраною популяцією. Коли той самий механізм застосовується до кожного об'єкта в розбитті val, без попереднього знання про те, які об'єкти дійсно потребують корекції, J&F падає до 68.7 — на 3.4 пункти *нижче* простої нескорегованої базової лінії, причому 178 об'єктів погіршуються проти 44, що покращуються. Дванадцять подальших спроб пом'якшення, організованих у чотири родини (гейтинг на рівні кадру, запобіжники на рівні об'єкта, попередній відбір на основі ознак та пом'якшення корекції), звужують, але ніколи не усувають цей розрив; найкраща конфігурація, стек запобіжника частоти корекції на рівні об'єкта з AND-гейтом на рівні кадру, все одно фінішує на 0.8 пункти нижче базової лінії на val і на 1.8 пункти нижче на test.

Ми представляємо цю роботу явно як статтю негативних результатів і діагностичну статтю, а не як звіт про покращену систему. Її внесок полягає в тому, щоб показати, з повним кількісним обліком, а не куратованою демонстрацією, що точність механізму корекції на випадках, для яких він був розроблений, майже не має значення для того, чи безпечно його розгортати: те, що визначає придатність до розгортання, — це *специфічність* механізму, тобто наскільки рідко він спрацьовує на об'єктах, які насправді не потребували корекції, — за базової частоти позитивного класу приблизно 10%. Розділ 2 розміщує цю рамку відносно попередніх робіт з пам'яті сегментації об'єктів відео, дрейфу відстеження, самокорекції під час тестування та виявлення за незбалансованих класів. Розділ 3 описує модель, бенчмарк і кожен випробуваний механізм. Розділ 4 повідомляє повні кількісні результати, з контрастом куратованої підмножини проти повної популяції як головним порівнянням. Розділ 5 обговорює, чому механізми на рівні об'єкта перевершили механізми на рівні кадру і чому попередній відбір та пом'якшення корекції обидва зазнали невдачі. Розділи 6–8 охоплюють обмеження, майбутні напрямки, що випливають з літератури (неперевірені), і висновки.

Внесок цієї статті полягає в такому: (1) методологічний висновок, незалежно проілюстрований як P2, так і P5, про те, що вимірний ефект механізму корекції на попередньо відібраній за істинною розміткою куратованій підмножині може суттєво перебільшувати — або навіть змінювати знак — його ефекту на повній, невідібраній популяції, на якій він мав би працювати при розгортанні; (2) механістична таксономія, що пояснює, чому чотири структурно різні родини пом'якшення (гейтинг на рівні кадру, запобіжники на рівні об'єкта, попередній відбір на основі ознак та пом'якшення корекції) зазнають невдачі кожна з окремої, діагностованої причини, а не з однієї спільної загальної причини (розділ 5); і (3) випуск усього коду, що реалізує базові політики, P5 та всі дванадцять варіантів пом'якшення, разом із файлами CSV з результатами на рівні об'єктів, що лежать в основі кожної таблиці розділу 4 (Заява про доступність даних).

2. Огляд пов'язаних робіт

2.1. SAM/SAM2 та промптована сегментація об'єктів відео

Цей проєкт працює повністю в парадигмі, яку встановив SAM (Kirillov et al., 2023) і яку SAM2 розширив на відео (Ravi et al., 2024): промпт-до-маски на замороженій моделі, без донавчання. Політики промптингу `box_centroid` та найбільшого зв'язного компонента, використані тут, є прямими застосуваннями інтерфейсу точка/бокс SAM, а розбиття `val/test` (293 та 278 об'єктів відповідно) є офіційними розбиттями SA-V, випущеними разом із SAM2 (Meta AI, 2024). Власне твердження SAM2 про ефективність — приблизно втричі менше взаємодій, ніж у попередніх інтерактивних методів VOS, — описує саме той режим, який ця стаття тестує на межі можливостей: не те, чи можна добре промптувати SAM2 на одному кадрі, а те, чи можна виправити власне поширення замороженої SAM2, без доступу до еталонного прогнозу, коли воно дрейфує. Висновок про те, що 83% відмов на SA-V `val` є дрейфом поширення з правильним стартом, — це оригінальна для цього проєкту декомпозиція, але вона збігається з незалежним діагнозом власної поведінки буфера пам'яті SAM2: Ding et al. (2024) у SAM2Long описують патерн

”накопичення помилки” (error accumulation), за якого помилкова маска, записана в пам’ять, поширюється вперед і, коли фіксований буфер пам’яті SAM2 зрештою втрачає початковий якірний кадр, допускає дрейф на візуально подібний дистрактор. Те, що два незалежні аналізи — експеримент з еталонним прогнозом і без еталонного прогнозу цього проекту та опублікований діагноз SAM2Long — приходять до одного й того самого механізму з різних кутів, є справжнім підтвердженням, а не спільною термінологією.

2.2. Дрейф відстеження, повторна ідентифікація та VOS на основі пам’яті

Лінія VOS на основі пам’яті, від якої походить SAM2, ілюструє прогресію архітектурних виправлень саме тієї проблеми, що досліджується тут. STM (Oh et al., 2019) встановила щільне зіставлення пам’яті у просторі ознак. XMem (Cheng and Schwing, 2022) додав трирівневу сенсорну/робочу/довготривалу пам’ять спеціально для того, щоб довгі відео не втрачали якірний кадр. Cutie (Cheng et al., 2023a) перейшла від зчитування пам’яті на рівні пікселя до рівня об’єкта, оскільки зіставлення на рівні пікселя вразливе до візуально подібних дистракторів. Підсумковий висновок цього проекту — що механізм корекції, запущений на власному сигналі поширення замороженої моделі, є чистою шкодою при неселективному застосуванні — є симптомом саме тієї проблеми вразливості до дистракторів, на яку націлена архітектура Cutie, але дизайн замороженої моделі, лише для інференсу, використаний тут, не може скористатися архітектурним виправленням.

Класичне візуальне відстеження пропонує незалежну лінію на тій самій проблемі. DaSiamRPN (Zhu et al., 2018) є найранішим прецедентом саме того режиму відмови, на який націлений P5: ”семантичні дистрактори” — візуально майже ідентичні об’єкти, які сигнал, заснований лише на зовнішньому вигляді, не може розрізнити. Випадки з власних даних цього проекту — sav_022396 (приблизно 15 майже ідентичних повітряних куль) та sav_035221 (дві візуально ідентичні підосви взуття) — є прямими прикладами цього режиму відмови. P5 відрізняється від DaSiamRPN тим, що його усвідомлення дистракторів є суто позиційним (екстраполяція центроїда за постійною швидкістю), а не навченим і заснованим на зовнішньому вигляді, — вибір, зроблений саме тому, що зовнішній вигляд неінформативний між візуально ідентичними екземплярами. Siam R-CNN (Voigtlaender et al., 2020) додає ще один релевантний прецедент: явне повторне виявлення та відстеження об’єктів-дистракторів поряд з ціллю, вирішене через динамічне програмування над кількома гіпотезами в часі, структурно відмінне від — і потенційно доповнювальне до — одногіпотезного повторного промпту цього проекту за тригером.

DEVA (Cheng et al., 2023b) пропонує подальший архітектурний контраст із власними однонаправленими, одноеталонними спробами стабілізувати корекцію цього проекту: вона відокремлює специфічну для завдання сегментацію від багаторазового модуля часового поширення і будує послідовний трек через двонаправлене поширення, об’єднуючи гіпотези сегментації з кількох кадрів, а не прив’язуючись до одного прямого ланцюга. Це структурно близько до того, до чого прагнуть власні D3 (ковзне вікно частоти корекції) та варіант еталонної маски консенсусу-K цього проекту, але DEVA досягає цього за допомогою навченої моделі двонаправленого злиття, а не евристики, накладеної на заморожений ві-

деопредиктор, — структурна причина, чому вона може вирішувати неоднозначність, яку однонапрямлені, одноеталонні евристичні цього проекту не змогли.

Дві специфічні для SAM2 подальші роботи датуються пізніше і безпосередньо звертаються до механізму, діагностованого тут незалежно. DAM4SAM (Videnovic et al., 2024) додає пам'ять з усвідомленням дистракторів з оновленням на основі інтроспекції — вирішуючи, чи довіряти і записувати результат кадру *перед* фіксацією його в пам'яті, — архітектурно відмінне від, але близьке за духом до, B1 цього проекту (пост-факт перевірка правдоподібності результату корекції) та A2 (запобіжник частоти на рівні об'єкта). Цей проект пізніше перевіряв базовий інтроспективний сигнал DAM4SAM окремо — розбіжність між власною основною та найкращою альтернативною кандидатною маскою SAM2, яку трекер обчислює на кожному кроці, але зазвичай відкидає, — як статичну ознаку попереднього відбору на рівні об'єкта (розділ 4.5) і виявив, що вона не несе більше прогностичного сигналу, ніж траєкторні ознаки E1 ($R^2 = 0.028$ проти 0.026 у E1). Справжній механізм DAM4SAM — це інший тип втручання: він діє безперервно, кадр за кадром, на те, що потрапляє в постійний банк пам'яті, а не як одноразове рішення про те, чи запускати корекцію для об'єкта взагалі. Пізніше, окреме дослідження поза межами дванадцяти спроб пом'якшення цієї статті безпосередньо перевірило саме цю динамічну роль на рівні пам'яті — пропускаючи запис кадру з підозрою на дистрактор у non-conditioning банк пам'яті SAM2, застосовано до простого, нескорегованого поширення взагалі без *gerprompt*-корекції — і воно не витримало зіткнення з повною валідаційною популяцією: куратований пілот $n=30$ на known-drift підмножині перевершив свій pre-committed гейт зі значним запасом (поріг 0.2, J&F=39.4 проти базової лінії 26.1), але той самий поріг дав чисту регресію на повній популяції з 293 об'єктів (J&F=71.3 проти базової лінії 72.1, на 0.8 пункти нижче) — та сама розбіжність куратована-підмножина-проти-повної-популяції, яку ця стаття документує для P5 (розділ 5). Більш амбітна половина механізму DAM4SAM — вставка постійного якірного кадру, що розв'язує дистрактори, у вікно уваги пам'яті SAM2 поза межами його звичайного розкладу нещодавності — перевірена лише частково: початкове занепокоєння тим, що таблиця навченого позиційного кодування SAM2 не має запису для довільної позарозкладової відстані, відтоді було розв'язане на етапі проектування (запропонований шлях через окремий, безперервно закодований канал object-pointer SAM2 — шлях коду, який заморожена модель вже застосовує для позарозкладових відстаней через власний вказівник кадру умови на довгих відео); відтоді реалізовано й перевірено на пілоті вужчий варіант — він підставляє вміст якірного object-pointer з останнього підтверджено чистого кадру в найстаріший слот вікна object-pointer SAM2, але зберігає фіксовану позиційну відстань цього слоту, — і він не пройшов свій заздалегідь зафіксований пілотний поріг (J&F=27.8 проти базової лінії 26.1 на known-drift підмножині $n=30$, поріг 29.1), тоді як вставка на справжній, потенційно значно більшій відстані якірного кадру лишається неперевіреною (розділ 7). SAM2Long (Ding et al., 2024) безперервно підтримує кілька кандидатних шляхів поширення і обрізає за кумулятивним показником, а не приймає бінарне рішення виявити-й-жорстко-перепромптувати, як це робить P5. SAM2Long не був реалізований чи перевірений у цьому проекті і позначений як неперевірений майбутній напрям у розділі 7. Жодне з розглянутих тут джерел не повідомляє про вимірювання одночасно точності корекції на попередньо відібраний за істинною розміткою підмножині справжніх позитивних випадків *та*

чистого ефекту того самого механізму, застосованого неселективно до повної популяції об'єктів, як двох явно розділених величин — це розділення є специфічним емпіричним внеском цього проекту в цю галузь.

2.3. Самокорекція під час тестування та упередженість підтвердження в заморожених моделях

Обмеження без еталонного прогнозу, що використовується протягом усього цього проекту — корекція без доступу до істинної розмітки під час інференсу — розміщує всю серію P5 всередині класу проблем адаптації під час тестування (test-time adaptation, TTA), хоча власні робочі документи проекту ніколи не використовують цей термін. Tent (Wang et al., 2020) є канонічним прикладом замороженої моделі, адаптованої онлайн лише за допомогою власних передбачень. CoTTA (Wang et al., 2022) є більш безпосередньо релевантною: вона діагностує, що довготривала самонавчальна адаптація на ненадійних псевдомітках спричиняє накопичення помилки, і пом'якшує це через усереднення ваг та стохастичне відновлення параметрів — стратегію демпфування, а не гейтингу. Власний висновок цього проекту про "каскад корекцій" — об'єкти з більш ніж 15 самокорекціями в ранньому варіанті без еталонного прогнозу деградує у середньому на 10.6 пункти, проти середнього приросту 20.6 пункти для об'єктів з 15 або менше корекціями, — є незалежно спостереженим прикладом тієї самої динаміки накопичення, яку CoTTA була побудована запобігати, а остаточний механізм A2 (запобіжник частоти корекції на рівні об'єкта) є, фактично, версією м'якого демпфування CoTTA з жорстким порогом, отриманою без звернення до літератури з TTA.

Arazo et al. (2020) дають загальну назву механізму для висновку про саморегулювальне джерело, спостереженого на ранньому етапі цього проекту: джерела корекції, які є тим самим типом сигналу, що й сигнал виявлення (власна остання надійна маска моделі, у кількох ранніх варіантах без еталонного прогнозу), деградує саме через ту динаміку упередженості підтвердження, яку Arazo et al. описують для псевдомаркування в класифікації. Huang et al. (2023), з літератури з міркувань LLM, а не зі сфери зору, включені як міждоменний структурний аналог: їхній висновок, що самокорекція без зовнішнього, надійного еталонного прогнозу часто робить результати гіршими, а не кращими, тісно перегукується з підсумковим висновком цього проекту. Обидва вказують на одну й ту саму структурну вимогу — чиста вигода самокорегульованої системи обмежена надійністю її тригера для "потрібна корекція", а не якістю корекції після спрацювання.

2.4. Специфічність тригера за незбалансованих класів

Це галузь, де одне зовнішнє джерело найбезпосередніше пояснює центральний кількісний результат проекту. Saito and Rehmsmeier (2015) формально показують, що за незбалансованих класів сильна продуктивність детектора на рівні окремого екземпляра не гарантує корисної чистої точності, оскільки хибнопозитивні результати на великому мажоритарному класі можуть переважити істинно позитивні результати на рідкісному міноритарному класі. Власні цифри цього проекту точно відтворюють цей патерн: приблизно 10% об'єктів SA-V val (близько 30 з 293) дійсно потребують корекції дрейфу, а неявна частота хибнопозитивних

спрацювань тригера підсумкового запуску на решті "здорової" популяції становить приблизно 68% — достатньо високо, щоб, навіть якщо корекція P5 є дуже точною на істинно позитивних випадках (індивідуальні прирости до 90 пунктів J&F), чистий ефект на рівні популяції був негативним. Це саме та динаміка колапсу точності через базову частоту, яку формалізують Saito and Rehmsmeier, отримана тут незалежно через пряме вимірювання, а не через звернення до літератури з класифікації за незбалансованих класів. Ми розглядаємо цю статтю як рамку незбалансованого виявлення для емпіричних результатів, наведених нижче.

3. Метод

3.1. Модель, бенчмарк і протокол оцінювання

У всіх експериментах використовується SAM2.1 Hiera-Tiny (коміт кодової бази SAM2 2b90b9f5ceec907a1c18123530e92e794ad901a4), заморожена протягом усього дослідження — жодні ваги не оновлюються в жодний момент цього дослідження. Перевірка переносимості підтверджує, що `box_centroid` не деградує на більшому чекпоінті Hiera-Small на повному DAVIS val (J&F-Mean 0.842 проти 0.8235 для Hiera-Tiny), але повна серія корекції дрейфу SA-V була проведена лише на Hiera-Tiny; Hiera-Small не був проведений через неї (див. розділ 6). Оцінювання використовує офіційний оцінювач SA-V (`sam2/sav_dataset/sav_evaluator.py`), який обчислює J (подібність області), F (точність межі) та $J\&F = (J+F)/2$, пропускаючи перший та останній анотовані кадри згідно з конвенцією SA-V. SA-V val включає 155 відео та 293 об'єкти; SA-V test включає 150 відео та 278 об'єктів. Апаратне забезпечення — одна NVIDIA RTX 4070 Ti (12 ГБ) з PyTorch 2.13.0+cu130. Кожне наведене число походить з цього офіційного запуску оцінювача на реальних передбаченнях, ніколи з проксі-оцінювання на основі LLM чи іншого евристичного методу.

3.2. Базова політика промптингу

Базова політика, `box_centroid`, будує щільний обмежувальний бокс навколо істинної маски на першому анотованому кадрі плюс позитивну точку в центроїді маски, і викликає `add_new_points_or_box` SAM2.1. Вона була обрана з десяти кандидатних політик промптингу на розробницькій підмножині DAVIS, валідована на повному DAVIS 2017 val (J&F-Mean = 0.8235, офіційний оцінювач `davis2017-evaluation`, 30 послідовностей / 1999 кадрів), а потім незалежно валідована на SA-V val (J&F = 72.1, J = 68.6, F = 75.6) та SA-V test (J&F = 74.4). Падіння приблизно на 10 пунктів з DAVIS до SA-V відображає те, що SA-V є складнішим, різноманітнішим бенчмарком (більше об'єктів на відео, більше оклюзії та зміни зовнішнього вигляду), а не зламаний конвеєр.

Аналіз режимів відмов 293 об'єктів SA-V val розкладає випадки з низьким показником (J&F < 40, n = 36) на дві причини: 6 з 36 (17%) — це відмови на кадрі промпу, коли модель вже зазнає невдачі на самому кадрі, з якого будується промпт, зазвичай через фрагментовану або розріджену істинну маску (`box_fill_ratio` < 0.2), що дає неінформативний обмежувальний бокс; 30 з 36

(83%) — це відмови через дрейф поширення, коли модель стартує правильно (IoU на кадрі промπτу ≥ 0.3), але деградує під час поширення. Експеримент з еталонним прогнозом на цих 30 об'єктах з дрейфом поширення — повторний промπτ з істинної маски кожного п'ятого анотованого кадру — відновлює J&F з 26.1 до 84.3 (+58.2 п.п.), встановлюючи, що відмова є відновлюваною проблемою збереження пам'яті, а не перцептивною межею.

Вторинне, незалежне виправлення націлене на меншу причину — колапс кадру промπτу: побудова початкового боксу з найбільшого зв'язного компонента істинної маски, а не з її повного (можливо, фрагментованого) обмежувального боксу. Ця політика, названа P2, є нульовою операцією для вже компактних масок і спочатку вимірювалася лише на 13 об'єктах з `box_fill_ratio` < 0.2 (J&F 47.1 $\rightarrow$ 61.6, +14.6 п.п.). Розділ 4 повідомляє, що відбувається, коли P2 застосовується до повної, нефільстрованої популяції.

3.3. P5: виявлення та корекція дрейфу на основі моделі руху

П'ять попередніх варіантів корекції дрейфу без еталонного прогнозу — одиночна еталонна власна маска, консенсус з 5 масок, ширші та вужчі пороги співвідношення площ, а також внутрішні `object_score_logits` SAM2 як альтернативний тригер — були випробувані першими, усі з повторним закріпленням через повторне впровадження власного нещодавнього вмісту маски моделі. Усі п'ять збіглися у вузькому діапазоні, кластеризованому в межах смуги 3.6 пункти (J&F $\in [23.8, 27.4]$ на підмножині дрейфу з 30 об'єктів), далеко нижче межі еталонного прогнозу у 84.3. Спільний механізм, "каскад корекцій", полягає в тому, що еталонна маска, яка використовується для корекції, генерується тим самим процесом, що й помилка, яку вона має виправити, тому одна неточна корекція погіршує еталон для наступної.

P5 змінює дві речі одночасно. По-перше, виявлення додає сигнал стрибка позиції поряд з наявним сигналом співвідношення площ: центроїд об'єкта екстрапольується з нещодавніх кадрів за припущенням постійної швидкості, і кадр позначається як дрейф, якщо фактичний центроїд відхиляється від екстрапольованої позиції більш ніж на $\text{jump_ratio} \times \sqrt{\text{EMA_area}}$. Це сигнал, який структурно пропускають тригери на основі співвідношення площ та впевненості: впевнена зміна ідентичності на дистрактор подібного розміру не змінює ні площу маски, ні власну впевненість моделі, але змінює позицію. По-друге, корекція повністю відмовляється від повторного впровадження власного вмісту маски моделі: на позначеному кадрі P5 видає свіжий промπτ з обмежувальним боксом, побудований лише з екстрапольованої позиції та розміру останньої прийнятої маски, через `add_new_points_or_box`, дозволяючи SAM2 повторно сегментувати те, що дійсно присутнє в цьому місці, а не продовжувати довіряти тому, що вона щойно (можливо, неправильно) відстежувала.

На підмножині дрейфу з 30 об'єктів нетюнінгований P5 досягає J&F = 35.9, приріст 9.1 пункти порівняно з базовою лінією без еталонного прогнозу `objscore` (26.8) та приріст 8.5 пункти порівняно з попереднім найкращим результатом без еталонного прогнозу, консенсусом масок (27.4). Калібрування координатним спуском чотирьох гіперпараметрів (`jump_ratio`, `low_ratio`, `high_ratio`, `ema_alpha`), після якого виконано спільну перевірку сіткою 3×3 навколо оптимального координатного спуску, збіглося на `jump_ratio` = 8.0 (стабільно в межах

6.0-9.0), `low_ratio` = 0.35, `high_ratio` = 2.5 (стабільно в межах 2.5-3.0), `ema_alpha` = 0.2, досягаючи J&F = 42.3 — найкращого результату основного калібрувального перебору, приросту 15.5 пункти порівняно з базовою лінією без еталонного прогнозу `objscore` (пізніше уточнення, описане нижче, підвищує його ще трохи, до 42.6). Ці головні показники 42.3/42.6 отримані з гіперпараметрів, налаштованих і оцінених на тій самій підмножині з 30 об'єктів — результат внутрішньовибіркової оптимізації, — тому їх слід читати як верхню межу досяжного приросту цього механізму, а не як оцінку продуктивності на відкладених даних; перевірка узагальнення `val`-до-`test`, наведена в розділі 4.5 (Таблиця 10), де приріст цієї ж каліброваної конфігурації падає з +15.5 п.п. на `val` до +2.0 п.п. на відкладеному `test`, є фактичним відкладеним доказом статті щодо того, наскільки слід довіряти цьому конкретному числу. Останній параметр, `min_area_eps`, був підтверджений на своєму початковому нетюнінгованому значенні 50 за допомогою окремого перебору. Шостий параметр, `vanish_retry_limit`, який обмежує послідовні повторні спроби корекції, спричинені зникненням об'єкта, не був частиною цього початкового чотирипараметричного калібрування; він був доданий пізніше, під час діагностики розбиття `test`, і представлений там, де він оцінюється (розділ 4.5). На окремих об'єктах з підтвердженою мультиінстанційною неоднозначністю прирости сягають аж +90.1 п.п. (`sav_022396`, приблизно 15 майже ідентичних повітряних куль: 5.2 → 95.3).

3.4. Родини пом'якшення, застосовані до P5 (і, де зазначено, до P2)

Застосування комбінованого конвеєра P2+P5 до повної, невідібраної популяції `val` з 293 об'єктів — підсумковий запуск — дало центральний діагностичний результат статті (розділ 4.3), мотивуючи дванадцять подальших спроб, організованих у чотири родини.

Гейтинг на рівні кадру. A1 вимагає одночасного спрацювання обох сигналів — співвідношення площ і стрибка позиції (AND-гейт) — замість будь-якого одного (початковий OR-гейт). B1 перевіряє *результат* завершенної корекції на відповідність нещодавній історії розміру/позиції і, якщо він неправдоподібний, замінює його консервативним резервним боксом "утримання позиції" (без екстраполяції швидкості) замість прийняття корекції.

Запобіжники на рівні об'єкта. A2 відстежує кумулятивну частоту корекцій кожного об'єкта (`n_corrections` / `frames_elapsed`) і, після розгону в 3 корекції, назавжди вимикає подальшу корекцію для цього об'єкта, як тільки частота перевищує поріг (0.15, налаштований на підмножині з 30 об'єктів і підтверджений на повному `val`). D1 повторно перебирає цей поріг (0.10, 0.20, 0.25) безпосередньо на повному `val`. D2 знижує вимогу розгону корекцій (1 або 2 замість 3). D3 замінює кумулятивну частоту на частоту, обчислену за ковзним вікном нещодавніх кадрів. D4 об'єднує A2 та A1 у стек.

Справжній попередній відбір (E1). Замість реагування після того, як корекції вже почалися (як це робить A2), E1 обчислює ознаки ризику з непокорегованого пробного проходу поширення, до будь-якої спроби корекції: (a) необроблена частота спрацювання тригера та статистика амплітуди стрибків площі/позиції; (b) частка загальної кількості кадрів об'єкта, що минула до його першого спрацювання (`first_trigger_frac`); (c) частка спрацювань об'єкта, що відбулися в

перших 10% або 20% його кадрів. Усі три були оцінені шляхом кореляції ознак пробного проходу з дельтою на рівні об'єкта підсумковий-мінус-лише-P2 на тих самих 293 об'єктах val.

Попередній відбір за внутрішньокадровим інтроспективним сигналом, натхненний DAM4SAM. Усі три родини ознак E1 підсумовують *траєкторію* об'єкта в часі. Структурно інший кандидатний сигнал походить з одного окремого кадру: SAM2 обчислює три кандидатні маски та їхні оцінки IoU на кожному кроці трекінгу, але зберігає лише найкраще оцінену, відкидаючи решту ще до того, як будь-який викликач може їх побачити. Дотримуючись ідеї інтроспективного виявлення дистракторів у DAM4SAM (Videnovic et al., 2024) — яка використовує розбіжність між основною та альтернативною кандидатними масками трекера як сигнал дистрактора, — відкинуті кандидати були перехоплені неінвазивно, обгортанням власного кроку вибору маски трекера під час виконання, а не модифікацією базової моделі, і використані для отримання шести ознак на рівні об'єкта з окремого непокореженого пробного проходу по всіх 293 об'єктах val: середня та максимальна розбіжність площі обмежувального прямокутника між основною та найкращою альтернативною маскою, частка кадрів з розбіжністю вище фіксованого порогу, позиція кадру першої події розбіжності, а також середній та мінімальний розрив між оцінками IoU основної та другої за якістю маски. Вони були оцінені тією самою методологією кореляції, що й E1, проти тієї самої дельти підсумковий-мінус-лише-P2 на тих самих 293 об'єктах.

Пом'якшення корекції (F1). Замість гейтингу того, чи коли відбувається корекція, F1 змінює як застосовується корекція: центр боксу повторного промπτу зміщується між повністю екстрапольованою позицією та власним (можливо, дрейфованим) поточним центроїдом моделі, $(1-w) \cdot \text{predicted_centroid} + w \cdot \text{raw_centroid}$, замість повного жорсткого перевизначення, з вагами змішування w , перебраними від 0.10 до 1.00.

3.5. Застереження щодо оцінювання

Кожне число, наведене в розділі 4, походить з офіційного оцінювача SA-V на реальних передбаченнях. Жодного формального тестування статистичної значущості — довірчих інтервалів методом бутстрепа, кількох зерен (seeds) чи р-значень — не було обчислено ніде в цій серії; висновки спираються на узгодженість напрямку ефекту за кількох незалежних маніпуляцій та, де були проведені обидва розбиття, на узгодженість між val і test. Це навмисне відхилення від власного заявленого протоколу оцінювання проекту, який визначає 95%-ві довірчі інтервали методом бутстрепа та триразове повторення з різними зернами як передумову для публікації заявленого покращення; ми обговорюємо це явно як обмеження в розділі 6, а не заднім числом додаємо статистику, яка не була обчислена.

Табл. 1: Перенесення базової лінії з DAVIS на SA-V.

Налаштування	Розбиття	n	J&F	J	F
box_centroid, Hiera-Tiny	DAVIS 2017 val (офіційне)	30 послід. / 1999 кадрів	82.4 (0.8235)	78.1	86.6
box_centroid, Hiera-Small	DAVIS 2017 val (офіційне)	30 послід. / 1999 кадрів	84.2 (0.842)	80.1	88.3
box_centroid, Hiera-Tiny	SA-V val (офіційне)	155 відео / 293 об'єкти	72.1	68.6	75.6
box_centroid, Hiera-Tiny	SA-V test (офіційне)	150 відео / 278 об'єктів	74.4	—	—

Табл. 2: Декомпозиція відмов SA-V val (n = 293 об'єкти).

Категорія	Частка	Середній J&F
box_fill_ratio < 0.2 (розріджена/фрагментована маска)	n = 13	47.1
box_fill_ratio 0.2-0.5	n = 72	71.1
box_fill_ratio ≥ 0.5 (компактна)	n = 208	74.0
Відмови на кадри промпту (серед J&F < 40, n = 36)	6/36 (17%)	—
Відмови через дрейф поширення (серед J&F < 40, n = 36)	30/36 (83%)	—

4. Результати

4.1. Базова лінія та декомпозиція відмов

4.2. Межа еталонного прогнозу та самореферентна межа без еталонного прогнозу

Усі п'ять самореферентних варіантів без еталонного прогнозу щільно кластеризуються, в межах смуги 3.6 пункти ($J\&F \in [23.8, 27.4]$), і залишаються далеко нижче межі еталонного прогнозу 84.3. Стратифікація одиночного маскового варіанта за кількістю самокорекцій показує бімодальний "каскад корекцій": об'єкти з ≤ 15 корекціями отримують середній приріст +20.6 п.п. (n=10), об'єкти з > 15 корекціями втрачають в середньому -10.6 п.п. (n=20).

Пілотний тест зовнішньої корекції (n = 6 об'єктів, Claude як рецензент, без інтеграції API, без істинної розмітки) перевірів, чи допомагає незалежне джерело корекції саме по собі: базова лінія тільки-objscore $J\&F = 18.5$ впала до 10.2 (-8.3 п.п.) після заміни саомаскової корекції зовнішньо намальованими боксами, зокрема колапс на 48.8 пункти на добре відстежуваному контрольному об'єкті (sav_010291, 84.6 → 35.8). Чотири з шести об'єктів були правильно позначені рецензентом як справді неоднозначні (плутанина ідентичності через кілька екземплярів) і рецензент утримався, а не вгадував.

4.3. P5: калібрування та контраст куратованої підмножини проти повної популяції

Колонка Δ у Таблиці 4 обчислена відносно 27.4 (варіант консенсусу-5), єдиної найкращої конфігурації серед п'яти попередніх спроб без еталонного прогно-

Табл. 3: Відновлюваність підмножини дрейфу поширення з 30 об'єктів.

Варіант	Сигнал виявлення	Джерело корекції	J&F
Базова лінія (box_centroid, одиначний промпт)	—	—	26.1
Періодичний повторний промпт за еталонним прогнозом (кожен 5-й кадр)	—	істинна маска	84.3 (+58.2 п.п.)
Одиночна еталонна власна маска	співвідношення площ до ЕМА (0.3–3.0)	остання власна маска моделі	25.8
Еталон консенсусу-5	співвідношення площ до ЕМА (0.3–3.0)	мажоритарне голосування останніх 5 масок	27.4
Широкий поріг	співвідношення площ до ЕМА (0.15–5.0)	остання власна маска моделі	23.8
Вузький поріг	співвідношення площ до ЕМА (0.5–2.0)	остання власна маска моделі	26.7
Тригер object_score_logits	внутрішній показник присутності (поріг 0.0)	остання власна маска моделі	26.8

Табл. 4: Шлях калібрування P5 на підмножині дрейфу з 30 об'єктів.

Конфігурація	J&F	Δ проти найкращого попереднього без еталонного прогнозу (27.4)
Нетюнінгований P5 (співвідношення площ + стрибок позиції, параметри за замовчуванням)	35.9	+8.5 п.п.
P5, калібровано лише jump_ratio = 8.0	39.3	+11.9 п.п.
P5, повністю калібрований (jump_ratio=8.0, low_ratio=0.35, high_ratio=2.5, ema_alpha=0.2)	42.3	+14.9 п.п.

зу, показаних у Таблиці 3. Наративна базова лінія, використана для головного показника "+15.5 п.п." в іншому місці цього розділу та в Таблиці 5, натомість становить 26.8 (варіант *objscore*): обидва є реальними опорними точками з Таблиці 3, але 27.4 — найкраща з попередніх спроб загалом, тоді як 26.8 — конкретна конфігурація, яку P5 зрештою замінює в розгорнутому, підсумковому порівнянні.

Відносно базової лінії без еталонного прогнозу *objscore* (26.8), повністю калібрований P5 отримує приріст +15.5 п.п. На рівні об'єктів 21/30 об'єктів покращуються, 4/30 погіршуються (найгірший: −4.3 п.п., без катастроф), а 5/30 залишаються незмінними. Найбільші прирости концентруються саме на об'єктах з незалежно підтвердженою мультиінстанційною неоднозначністю ідентичності: *sav_022396* (5.2 → 95.3, +90.1 п.п.), *sav_035221/001* (11.4 → 63.3, +51.9 п.п.), *sav_047467/002* (24.2 → 64.1, +39.9 п.п.).

Табл. 5: (Головна) Куратована підмножина істинно позитивних об'єктів проти повної, невідібраної популяції — центральний емпіричний результат статті.

Популяція	n	Умова	J&F	Δ проти еталону без корекції
Попередньо відібрані за істинною розміткою об'єкти зі справжньою відмовою через дрейф	30	Повністю калібрований P5	42.3	+15.5 п.п. проти базової лінії без еталонного прогнозу <i>objscore</i> (26.8)
Повний, невідібраний SA-V val	293	Комбінація P2+P5, без гейтингу (підсумковий запуск)	68.7	−3.4 п.п. проти простої базової лінії <i>box_centroid</i> (72.1)

Результати на рівні об'єктів на повній популяції: 44/293 покращуються, 178/293 погіршуються, 71/293 без змін. Покращення стосуються тих самих об'єктів, для яких був калібрований P5 (*sav_022396*: 5.0 → 95.3, +90.3 п.п.; *sav_022456*: 0.4 → 91.2, +90.8 п.п.; *sav_045706*: 5.6 → 95.3, +89.7 п.п.), але погіршення численніші й порівняно серйозні, вражаючи об'єкти, які базова лінія вже добре відстежувала: *sav_014969/000* (89.6 → 1.2, −88.4 п.п.), *sav_024930/001* (88.2 → 6.2, −82.0 п.п.), *sav_021068/000* (78.3 → 10.7, −67.6 п.п.), і принаймні 15 подальших об'єктів втрачають понад 35 пунктів. Приблизно 10% об'єктів val (близько 30 з 293) дійсно потребують корекції дрейфу; неявна частота хибнопозитивних спрацювань тригера на решті "здорових" ~90% становить приблизно 68%.

Дві незалежні діагностики підтверджують, що проблема — саме тригер, а не крок корекції. По-перше, 200/293 об'єктів (68% всієї популяції) хоча б раз спрацьовують тригер стрибка позиції, і ця підгрупа має середню дельту −5.17 п.п. — гірше за середнє по популяції, — що вказує на те, що позиційний сигнал на практиці не є більш специфічним до справжніх змін ідентичності, ніж сигнал співвідношення площ, попри задумку дизайну, що суто просторовий сигнал повинен краще протистояти плутанині між візуально ідентичними екземплярами. По-друге, частота корекції на об'єкт є чітко монотонним предиктором результату:

Табл. 6: Частота корекції проти результату, повний SA-V val (n = 293). Підпідрахунки покращено/погіршено по кошиках, зафіксовані під час ретроспективного аналізу, тут опущені, оскільки вони не підсумовуються до тих самих загальних показників покращено/погіршено на рівні популяції, наведених для підсумкового запуску вище (розбіжність, присутня в базовому експериментальному журналі, яку ця стаття не намагається мовчки вирішити); наведений нижче тренд середньої дельти є однозначним і саме він мотивував дизайн A2.

Частота корекції (n_corrections / frames_elapsed)	n об'єктів	Середня Δ
< 0.05	88	+3.28 п.п.
0.05-0.15	88	-3.26 п.п.
0.15-0.30	67	-5.70 п.п.
> 0.30	50	-11.87 п.п.

4.4. P2 ізольовано на повній, невідібраній популяції — друга ілюстрація того самого патерну

Табл. 7: P2 (промптинг за найбільшим зв'язним компонентом), куратована підмножина проти повної популяції.

Популяція	n	J&F	Δ проти box_centroid
Куратована: лише об'єкти з розрідженою маскою (box_fill_ratio < 0.2)	13	61.6	+14.6 п.п. (4/13 суттєво покращилися до +90.8 п.п., 8/13 без змін, 1/13 погіршився -11.8 п.п.)
Повний SA-V val (ізольовано, без P5)	293	72.5	+0.4 п.п.
Повний SA-V test (ізольовано, без P5)	278	74.1	-0.3 п.п.

На куратованій підмножині P2 виглядає як безкоштовне, універсально безпечне виправлення. На повній, невідібраній популяції воно є високоваріативним і не безризиковим: val показує 21/293 покращення об'єктів (до +90.8 п.п.) проти 24/293 погіршень (до -48.5 п.п., sav_024172/003: 72.5 $\rightarrow$ 24.0); test показує 16/278 покращень (до +50.7 п.п.) проти 31/278 погіршень (до -38.2 п.п., sav_042227/000: 86.4 $\rightarrow$ 48.2), причому хвіст погіршень домінує на test (чистий -0.3 п.п.). P2 на підмножині test з 13 об'єктів, використаній для початкового куратованого вимірювання, побайтово ідентичний базовій лінії (немає фрагментованих масок), нульовий ізольований ефект 0.0 п.п., повністю інертний на цьому розбитті, на противагу +14.6 п.п. на аналогічній підмножині val. Обидва "підтверджені" позитивні результати в серії цього проекту (P2 на його куратованій підмножині, P5 на його куратованій підмножині) суттєво або повністю втрачають свій ефект, будучи вимірними на повній, невідібраній популяції.

4.5. Спроби пом'якшення

D3 (ковзне вікно частоти корекції), E1 (усі три варіанти попереднього відбору) та перевірка розбіжності мультимасок, натхненна DAM4SAM, так і не дійшли до повного скорегованого запуску, оскільки дешеві пілоти або кореляції на вже зі-

Табл. 8: Пом'якшення на рівні кадру та на рівні об'єкта, повний SA-V val і (де проведено) test.

Конфігурація	Родина	val J&F	val Δ	val покращено/ погіршено	test J&F	test Δ
Базова лінія (box_centroid)	—	72.1	—	—	74.4	—
P2 ізольовано	лише промпт	72.5	+0.4 п.п.	—	74.1	−0.3 п.п.
Підсумковий OR-гейт (P2+P5, без гейту)	еталон	68.7	−3.4 п.п.	44/178	не проведено	—
A1: AND-гейт (потрібні обидва тригери)	гейтинг на рівні кадру	69.0	−3.1 п.п.	50/167	не проведено	—
B1: перевірка правдоподібності результату корекції	гейтинг на рівні кадру	68.2	−3.9 п.п.	48/199	не проведено	—
A2: запобіжник частоти (поріг 0.15)	запобіжник на рівні об'єкта	71.1	−1.0 п.п.	49/189	72.2	−2.2 п.п.
D1: поріг частоти 0.10	запобіжник на рівні об'єкта	71.2	−0.9 п.п.	—	не проведено	—
D1: поріг частоти 0.20	запобіжник на рівні об'єкта	70.5	−1.6 п.п.	—	не проведено	—
D1: поріг частоти 0.25	запобіжник на рівні об'єкта	70.3	−1.8 п.п.	—	не проведено	—
D2: розгон=1 (на конфігурації D4)	запобіжник на рівні об'єкта	70.9	−1.2 п.п. (−0.4 п.п. проти D4)	—	не проведено	—
D4: A2 (0.15) + A1 у стеку	на рівні об'єкта + на рівні кадру	71.3	−0.8 п.п.	—	72.6	−1.8 п.п.
F1: м'яке підштовхування, w=0.10 (на підсумковому запуску, без A1/A2)	пом'якшення корекції	67.9	−4.2 п.п.	—	не проведено	—

браних чи спеціально проведених пробних даних були однозначно негативними (D3) або не показали придатного сигналу (E1, розбіжність мультимасок); Таблиця 9 наводить ці перевірки.

Табл. 9: Дешеві перевірки-гейти, що закрили напрямок без повного запуску.

Напрямок	Перевірка	Результат
D3: ковзне вікно частоти корекції (розміри 20/30/50/100)	пілот $n=30$ проти кумулятивного A2 (40.2)	Найкраще вікно (100) все ще -0.4 п.п.; жодне вікно не перевершило кумулятивне; закрито без повного запуску
E1-rate: 6 ознак пробного проходу (частота тригера, амплітуда)	Множинна регресія, всі 293 об'єкти val, проти дельти підсумковий-мінус-лише-P2	$R^2 = 0.026$; немонотонні кошики за однією ознакою; жодного придатного сигналу
E1-timing: first_trigger_frac як живий гейт	Точна реконструкція копіюванням файлів гейтованого конвеєра, 293 об'єкти val, пороги $T \in [0.02, 0.70]$	Крива насичується точно на вже відомій, неузагальнюваній межі лише-P2 (72.5), ніколи її не перевищує
E1-timing: частка тригерів у перших 10%/20% кадрів	Кореляція, ті самі 293 об'єкти	$r = -0.111 / -0.109$ (усі), немонотонні кошики; комбінований R^2 з 9 ознак $= 0.044$
Розбіжність мультимасок (натхненна DAM4SAM): 6 внутрішньокадрових інтроспективних ознак	Множинна регресія, окремий пробний прохід, всі 293 об'єкти val, проти дельти підсумковий-мінус-лише-P2	$R^2 = 0.028$ (практично не змінено відносно 0.026 у E1); найсильніша одинична ознака $r = -0.131$ ($p = 0.024$) не витримує тесту рангової кореляції Спірмена ($\rho = +0.054$, $p = 0.35$, знак змінюється) і є 1 з 6 перевірених ознак без поправки на множинні порівняння; жодного придатного сигналу

F1 (м'яке підштовхування) був єдиним пом'якшенням, чий пілот $n=30$ був різко негативним при кожній перевірці вазі, але все одно був запущений у повному масштабі, за міркуванням, що механізм, який змінює як застосовується корекція (а не коли чи чи взагалі), міг би теоретично допомогти 263 об'єктам поза куратованою підмножиною, навіть шкодячи 30 усередині неї. Цього не сталося: J&F на повному val = 67.9 ($w=0.10$), гірше за некерований OR-гейт підсумкового запуску (68.7) і найгірший поодинокий результат усієї серії.

На test P5 (з гіперпараметрами, каліброваними лише на val) дає два катастрофічні погіршення, відсутні на val: sav_017171/000 ($87.5 \rightarrow 53.7$, -33.8 п.п., спричинене швидким зростанням розміру цілі, тоді як бокс повторного промπτу зберігає застарілий, заниженого розміру еталон) та sav_004755/000 ($34.3 \rightarrow 0.0$, -34.3 п.п., спричинене зникненням цілі та впевненим повторним закріпленням P5 на неправильному об'єкті, що потім самопідсилюється на всіх 68 решти

Табл. 10: Розрив узагальнення val-до-test P5 на куратованій підмножині дрейфу.

Розбиття	n	Базовий J&F	J&F P5	Δ	Покращено/Погіршено/Без змін
val	30	26.8	42.3	+15.5 п.п.	21/4/5
test	25	26.9	28.9	+2.0 п.п.	10/10/5

анотованих кадрах). Обидві катастрофи походять з тригера співвідношення площ (`position_triggers = 0` в обох випадках). Цільове виправлення, що обмежує послідовні повторні спроби, спричинені зникненням (`vanish_retry_limit`), трохи покращує val (42.3 $\rightarrow$ 42.6 при межі 10), але залишає обидві катастрофи на test повністю незмінними, оскільки кожна з них походить з однієї впевнено неправильної першої корекції, а не з ланцюга повторних спроб.

4.6. Остаточний результат

Табл. 11: Остаточне порівняння: найкраще пом'якшення проти базової лінії, обидва розбиття.

Розбиття	Базова лінія	D4 (найкраще пом'якшення)	Δ
val	72.1	71.3	−0.8 п.п.
test	74.4	72.6	−1.8 п.п.

Жодна конфігурація у всій серії — п'ять ранніх варіантів без еталонного прогнозу (Таблиця 3), P2, P5, підсумковий запуск, A1, B1, A2, D1–D4, три варіанти E1, перевірка розбіжності мультимасок, натхнення DAM4SAM, та F1 — не перевищує просту базову лінію `box_centroid` на жодному з розбиттів.

D4 наводиться як єдине найкраще пом'якшення для конкретності, але його перевага над наступними найближчими конфігураціями є вузькою: на val D4 (−0.8 п.п.), D1 при порозі 0.10 (−0.9 п.п.) та A2 (−1.0 п.п.) перебувають у межах 0.1–0.2 пункти один від одного (Таблиця 8) — розрив, ймовірно, у межах похибки вимірювання на популяції з 293 об'єктів, для якої не було обчислено жодних довірчих інтервалів, кількох зерен чи тестів значущості (розділ 3.5). Надійним є якісний висновок: D4, A2 та D1@0.10 усі залишаються чітко нижче нескорегованої базової лінії; їхнє точне відносне ранжування — це те, чого цей протокол оцінювання не може підтвердити.

5. Обговорення

Об'єднавча призма для кожного результату розділу 4 — це розрізнення між точністю корекції (наскільки добре корекція відповідає істинній розмітці, коли вона дійсно потрібна) та специфічністю тригера (наскільки рідко механізм спрацьовує на об'єктах, які цього не потребували). Кожна спроба до підсумкового запуску вимірювала лише першу величину, на популяції, вже відомій як така, що потребує корекції; підсумковий запуск був першою точкою, в якій друга величина взагалі вимірювалася, і він показав, що саме специфічність, а не точність, визначає, чи

безпечно розгортати механізм. Крок корекції P5 є чудовим за єдиним стандартом, який могли застосувати попередні експерименти на куратованій підмножині — він перевершує кожне попереднє джерело корекції без еталонного прогнозу зі значним відривом і наближається до приростів на рівні еталонного прогнозу на справжніх випадках зміни ідентичності через кілька екземплярів. Ніщо з цього не передбачає, що станеться, коли та сама логіка тригера зіткнеться з популяцією, де приблизно 90% об'єктів взагалі не потребують корекції: тригер навіть з помірною частотою хибнопозитивних спрацювань на цій більшості завдає більше сукупної шкоди, ніж можуть компенсувати прирости меншості, а це саме та арифметика, яку формалізують Saito and Rehmsmeier (2015) для класифікації за незбалансованих класів, і саме те, що показує розподіл 178 проти 44 об'єктів.

Це також пояснює, чому механізми на рівні об'єкта (A2, D4) перевершили механізми на рівні кадру (A1, B1), навіть якщо жоден з них не усунув розрив до базової лінії. AND-гейт A1 припускає, що сигнали співвідношення площ і стрибка позиції є принаймні частково незалежними доказами дрейфу, тому вимога обох мала б придушити хибнопозитивні спрацювання більше, ніж будь-який окремих. Дані відкидають це припущення: 68% всієї популяції *val* хоча б раз спрацьовують тригер стрибка позиції, і середній результат цієї підгрупи (–5.17 п.п.) гірший за середнє по популяції, оскільки обидва сигнали реагують на одні й ті самі законні події — швидка зміна масштабу чи швидкий рух одночасно зсувають центроїд і площу. Вимога узгодження між двома корельованими, спільно неспецифічними сигналами відновлює лише 0.3 п.п. відносно OR-гейту. Перевірка правдоподібності результату корекції B1 зазнає невдачі з пов'язаної, але окремої причини: її "безпечний" резервний варіант (утримання позиції, без екстраполяції швидкості) безпечний лише для повільних або нерухомих об'єктів, а популяція, де тригер спрацьовує найчастіше, непропорційно складається зі швидкорухомих об'єктів, саме там, де неекстрапольований резервний варіант найбільше відстає від справжньої позиції. Оскільки швидкість скидається до нуля після будь-якої корекції, включно з відхиленою, цей резервний варіант створює новий стрибок позиції на наступному ж кадрі, запускаючи ще одну корекцію і ще одне відхилення — самопідсилювальний цикл неправильного закріплення, що дав більше погіршень (199/293), ніж будь-який з гейтів, які він мав покращити. A2 і D4 натомість діють на основі накопиченої історії частоти корекцій об'єкта, а не будь-якого одного кадру тригера чи результату. Це принципово інший тип сигналу: він не намагається відрізнити законну подію швидкого руху від справжньої події дрейфу в момент, коли будь-яка з них відбувається (режим відмови як A1, так і B1), а натомість визнає, заднім числом, що об'єкт, який хронічно генерує корекції з високою частотою, поводить як та популяція, де P5 завдає чистої шкоди, і припиняє коригувати цей об'єкт незалежно від причини будь-якого окремого спрацювання. Це не зменшує частоту хибнопозитивних спрацювань тригера; це обмежує шкоду, яку може накопичити об'єкт із хронічними спрацюваннями тригера, тому найгірше окреме погіршення під A2 (–65.7 п.п.) помітно менше, ніж під OR-гейтом (–88.4 п.п.), тоді як кожна значна істинно позитивна перемога зберігається недоторканою — короткі, точні корекції ніколи не накопичують достатньої частоти, щоб спрацював запобіжник.

Спроби попереднього відбору E1 не виявили практично жодного сигналу ($R^2 = 0.026$ для необроблених ознак частоти/амплітуди, немонотонні кошики всюди) з тієї ж основної причини, з якої зазнав невдачі A1: ознаки, доступні з непокорого-

ваного пробного проходу, — як часто і наскільки серйозно перевищується поріг, — вимірюють те саме, що вже вимірює живий тригер, просто без дії на цій основі. Вони не можуть відрізнити "тригер правильно виявляє зміну ідентичності" від "тригер неправильно реагує на звичайний швидкий рух чи зміну масштабу", оскільки саме це розрізнення і є проблемою дискримінації, яку сам тригер не може вирішити; повторне обчислення тієї самої статистики на тій самій непокорегованій траєкторії не вносить нової інформації, здатної її вирішити. Єдиний варіант E1, що показав реальну, ненульову кореляцію — час першого спрацювання об'єкта, — виявився, при реконструкції в повному діапазоні порогів, таким, що насичується точно на вже відомій, неугальнюваній межі лише-P2 (72.5) і ніколи її не перевищує: гейт не відкривав нового джерела сигналу, він поступово вимикав P5, повертаючись до лише-P2 у міру звуження порогу, а лише-P2 уже відомо, що змінює знак на test.

Пізніша перевірка розглянула те саме питання з категорично іншим сигналом — не траєкторією обраної маски в часі, а власною незгодою SAM2 між кількома гіпотезами в межах одного кадру (розбіжністю між основною та найкращою альтернативною кандидатною маскою, у дусі інтроспективного виявлення дистракторів DAM4SAM) — і виявила ту саму відсутність сигналу ($R^2 = 0.028$, практично не змінено відносно 0.026 у E1; її єдина номінально значуща одинична ознака не витримує рангового тесту і не має поправки на множинні порівняння). Це є певним доказом, хоча й не доказом остаточною, оскільки випробувано лише дві родини ознак, що дискримінація, потрібна цьому проєкту, не відновлювана з дешевих інтроспективних сигналів без еталонного прогнозу жодного із загальних типів: ні історія маски в часі, ні власні конкурентні гіпотези трекара в межах кадру не відрізняють справжню зміну ідентичності від звичайної події руху чи зміни масштабу, яка випадково перетинає ті самі порогові значення тригера.

Невдача F1 є найбільш механістично прямою з дванадцяти спроб. Уся перевага P5 над попередніми самореферентними варіантами корекції походить з відмови довіряти власній поточній, можливо дрейфованій позиції моделі та натомість повторної сегментації з чисто екстрапольованої позиції. Змішування будь-якої частки власного центроїда моделі назад у бокс повторного пром프트 безпосередньо повторно вносить ненадійний сигнал, який P5 був побудований відкинути, і робить це при кожній корекції, включно з істинно позитивними випадками, які становлять практично всю користь P5. Те, що найм'якше перевірене змішування ($w = 0.10$) уже коштувало 5.6 пункти на куратованій підмножині істинно позитивних випадків, без плато поблизу нуля, узгоджується з цим: не було безпечної кількості повторного внесення скомпрометованої позиції, оскільки саме позиція є тим, чого механізм не повинен використовувати.

Друга тема незалежно пронизує кілька результатів: вимірювання на куратованій або попередньо відібраній за істинною розміткою підмножині ненадійно передбачають повний ефект на невідібраній популяції, і це справджувалося в обидва боки та на обох механізмах, випробуваних у такий спосіб. Приріст P5 на val (+15.5 п.п. на підмножині істинно позитивних випадків) впав до +2.0 п.п. на аналогічній відкладеній підмножині test, з двома катастрофічними погіршеннями на test, відсутніми на val. Ізольований ефект P2 змінив знак між розбиттями (+0.4 п.п. val, -0.3 п.п. test). А в межах одного розбиття пілот порогу розгону D2 на підмножині з 30 об'єктів показав практично безкоштовний приріст (+0.2 п.п.), який перетворився на погіршення -0.4 п.п. у повному масштабі, оскільки

підмножина з 30 об'єктів — відібрана за наявності кількох послідовних корекцій — структурно виключає сценарій (одна необхідна корекція, заблокована одним попереднім випадковим спрацюванням), який спричинив погіршення на повній популяції. Жоден із цих розворотів не вимагало іншого механізму для отримання; той самий механізм, виміряний на по-різному складеній популяції, щоразу давав відповідь з іншим знаком.

Останнє зауваження щодо охоплення стосується центрального твердження статті. Конкретні наведені тут числа — базова частота позитивного класу $\sim 10\%$, частота хибнопозитивних спрацювань тригера $\sim 68\%$ та чистий ефект -3.4 п.п. — є властивостями саме цього механізму (тригерів співвідношення площ і стрибка позиції P5), саме цього замороженого чекпоінта (SAM2.1 Hiera-Tiny) та саме цього бенчмарку (SA-V), і їх не слід вважати такими, що чисельно переносяться на інший механізм корекції, модель чи набір даних. Якісний патерн — окреме питання: будь-який механізм корекції без еталонного прогнозу, чий тригер валідуються щодо точності лише на популяції, вже відомій як така, що потребує корекції, і ніколи не вимірюється щодо поведінки хибнопозитивних спрацювань на (як правило, значно більшій) популяції, яка цього не потребує, структурно вразливий до тієї самої арифметики базової частоти, яку формалізують Saito and Rehmsmeier (2015) для класифікації за незбалансованих класів загалом — специфічні для механізму, моделі та набору даних числа будуть відрізнятися, але базова вимога вимірювати специфічність на невідібраній популяції перед розгортанням не залежить від жодної з цих специфік. Тому ми очікуємо, що саме вузьке місце специфічності тригера, а не його точна величина, узагальниться за межі налаштування цього дослідження. З цього випливає прямий методологічний наслідок: будь-який механізм корекції без еталонного прогнозу повинен повідомляти як свою точність на куратованій, попередньо відібраній за істинною розміткою підмножині істинно позитивних випадків, *так* і свій чистий ефект при неселективному застосуванні до повної цільової популяції, перш ніж вважатися валідованим для розгортання — власні результати P2 і P5 цієї статті кожен виглядав би однозначно позитивним, якби було взято лише перше вимірювання.

6. Обмеження

Масштаб моделі. Повна серія корекції дрейфу (P5 та всі дванадцять пом'якшень) була проведена лише на SAM2.1 Hiera-Tiny. Hiera-Small перевірявся лише щодо переносимості базового `box_centroid` на DAVIS val (J&F-Mean 0.842 проти 0.8235), не проведений через жодну частину дослідження корекції дрейфу SA-V. Чи є проблема специфічності тригера, діагностована цією статтею, залежною від розміру чекпоінта, невідомо.

Узагальнення на одному бенчмарку. Усі результати корекції дрейфу виміряні на SA-V. Чи справджується та сама динаміка хибнопозитивних спрацювань на інших бенчмарках VOS з іншою щільністю об'єктів, частотою оклюзії чи статистикою руху, не перевірено.

Нерівномірна глибина дослідження серед спроб пом'якшення. Дванадцять спроб пом'якшення не отримали порівнянно ретельного дослідження. Сам P5 та родина A1/A2/D1/D4, що стала остаточним найкращим результатом, отримали багатопараметричне калібрування координатним спуском або пошуком по

сітці (розділ 3.3; Таблиця 8). D2, D3, F1, E1 та перевірка розбіжності мультимасок, натхненна DAM4SAM, натомість покладалися на дешевий гейт-пілот $n=30$ або кореляцію на зібраних пробних даних перед будь-якою повномасштабною скорегованою фіксацією; D3, всі три варіанти E1 та перевірка розбіжності мультимасок так і не отримали повномасштабного *скорегованого* запуску взагалі, коли їхні пілотні або кореляційні перевірки виявилися негативними (Таблиця 9), і навіть там, де повномасштабний скорегований запуск відбувся, для D2 (розгон=1) та F1 ($w=0.10$) була перевірена лише одна конфігурація — попри те, що власний перебір $n=30$ F1 був немонотонним за вагою змішування (вага=0.75 показала гірший результат, $J\&F=32.6$, ніж вага=1.00, $J\&F=35.2$, а не просте монотонне погіршення зі зростанням ваги). Рамку статті “дванадцять спроб пом’якшення” тому не слід читати як дванадцять порівнянно ретельних досліджень.

Протокол дешевого пілоту на малій вибірці має задокументований режим відмови. Стандартна практика проекту — дешевий пілот $n=30$ чи кореляція на наявних або спеціально проведених пробних даних перед фіксацією до дорогого (5–9 годин) повного запуску на всьому наборі даних — правильно передбачила напрямком для більшості пом’якшень (D1, D3, усі три варіанти E1, перевірка розбіжності мультимасок, F1), але зазнала невдачі принаймні один раз: пілот $n=30$ для D2 показав практично безкоштовну зміну порогу, яка перетворилася на реальне погіршення в повному масштабі, оскільки куратована підмножина з 30 об’єктів не містить сценарію відмови (одне випадкове раннє спрацювання, що назавжди блокує пізнішу необхідну корекцію), який спричинив втрату на повній популяції. Читачам не слід розглядати результат пілоту $n=30$ сам по собі як остаточний для цього класу механізмів.

Відсутність формального тестування статистичної значущості. Жодних довірчих інтервалів методом бутстрепу, повторень з кількома зернами чи р-значень не було обчислено ніде в цій серії, для жодного порівняння. Усі наведені дельти є точними точковими оцінками з окремих запусків проти офіційного оцінювача. Висновки цієї статті спираються на узгодженість напрямку ефекту за незалежних маніпуляцій та, де були виміряні обидва розбиття, на узгодженість між *val* і *test* — не на формальну значущість. Це справжнє обмеження, і воно заявлене тут, а не заднім числом доповнене вигаданою статистикою.

7. Майбутня робота

Наступне — це кандидатні напрямки, похідні від літератури, що націлені на діагностоване вузьке місце — специфічність тригера, а не точність корекції, — і які **не** були реалізовані чи перевірені цим проектом. Це лише пропозиції, взяті з джерел, розглянутих у розділі 2, і їх не слід читати як розширення власних результатів цієї статті.

1. **Інтроспективний гейтинг пам’яті на рівні об’єкта**, у стилі DAM4SAM (Videnovic et al., 2024): замість гейтингу за сигналом тригера, обчисленим *після* спроби корекції (як робив B1), або за накопиченою частотою корекцій (як робив A2), вирішувати, чи довіряти і записувати поширену маску цього кадру в пам’ять *перед* тим, як вона зможе забруднити майбутні кадри — потенційно запобігаючи відмові через один поганий кадр, задокументований

для sav_004755, де одна неправильна корекція стала постійним, самопідсилювальним якорем. Цей проєкт перевірів базовий інтроспективний сигнал DAM4SAM у вужчій ролі, як статичну ознаку попереднього відбору на рівні об'єкта — розбіжність між основною та найкращою альтернативною кандидатною маскою SAM2, — і не виявив придатного сигналу (розділ 4.5). Це інше питання, ніж поставлене тут: справжній гейт DAM4SAM діє безперервно, кадр за кадром, на те, що потрапляє в постійний банк пам'яті, а не як одноразове рішення про запуск корекції для об'єкта взагалі. Пізніше, окреме дослідження поза межами дванадцяти спроб пом'якшення цієї статті відтоді перевірило саме цю динамічну роль на рівні пам'яті, застосовану до простого, нескорегованого поширення взагалі без reprompt-корекції: пропускаючи запис кадру з підозрою на дистрактор у non-conditioning банк пам'яті SAM2. Куратований пілот $n=30$ на known-drift підмножині перевершив свій pre-committed гейт зі значним запасом (поріг 0.2, $J\&F=39.4$ проти базової лінії 26.1), але той самий поріг дав чисту регресію на повній валідаційній популяції з 293 об'єктів ($J\&F=71.3$ проти базової лінії 72.1, на 0.8 пункти нижче) — та сама розбіжність куратована-підмножина-проти-повної-популяції, яку ця стаття документує для P5. Більш амбітна половина механізму DAM4SAM, якої цей простіший гейт пропуску запису не може досягти, — вставка постійного якірного кадру, що розв'язує дистрактори, у вікно уваги пам'яті SAM2 поза межами його звичайного розкладу нещодавності, — перевірена лише частково: початкове занепокоєння тим, що таблиця навченого позиційного кодування SAM2 не має запису для довільної позарозкладової відстані, відтоді було розв'язане на етапі проектування (запропонований шлях через окремий, безперервно закодований канал object-pointer SAM2 — шлях коду, який заморожена модель вже застосовує для позарозкладових відстаней через власний вказівник кадру умови на довгих відео). Відтоді реалізовано й перевірено на пілоті вужчий варіант: коли попередній кадр підозрюється в дистракторі, вміст динамічно оновлюваного якірного object-pointer з останнього підтверджено чистого кадру замінює найстаріший слот ($t_diff = 15$) вікна object-pointer SAM2, а загальна кількість токенів-вказівників не змінюється. На known-drift підмножині $n=30$ він досяг $J\&F=27.8$ проти базової лінії 26.1 (5 об'єктів покращилися, 2 погіршилися, 23 без змін), що нижче задалегідь зафіксованого пілотного порогу 29.1, тому напрямок закрито без прогону на повній валідації. Цей варіант зберігає фіксовану позиційну відстань слоту; вставку на справжній, потенційно значно більшій відстані якірного кадру — саме той варіант, який підтримує наведений вище аргумент про безперервне кодування, — не перевіряли, і цей негативний пілот про неї нічого не каже.

2. **Багатошляхове поширення**, у стилі SAM2Long (Ding et al., 2024): безперервно підтримувати кілька кандидатних шляхів поширення на об'єкт, обрізаних за кумулятивною впевненістю, замість однопотезного дизайну виявити-й-жорстко-перепромптувати цього проєкту, структурно уникаючи незворотної фіксації на одній поганій корекції.
3. **Навчена, заснована на зовнішньому вигляді дискримінація дистракторів у поєднанні з позиційним сигналом P5**, у стилі DaSiamRPN (Zhu

et al., 2018): P5 використовує позицію саме тому, що зовнішній вигляд не може розділити візуально ідентичні екземпляри; гібридний сигнал — позиційний пріор, гейтований чи зважений навченим показником усвідомлення дистракторів, — не був випробуваний і міг би теоретично підвищити специфічність на здоровій популяції без втрати чутливості на справжніх мультиінстанційних випадках.

4. **Повторне виявлення об'єктів на рівні об'єкта з мультигіпотезним динамічним програмуванням**, у стилі Siam R-CNN (Voigtlaender et al., 2020): відстежувати кандидатні ідентичності дистракторів поряд з ціллю в часі та вирішувати неоднозначність ретроспективно через крок асоціації треклетів, а не через одноразове, лише прямопроходове, одне рішення повторного промπτу за тригером.
5. **Зчитування пам'яті на рівні об'єкта замість корекції на рівні боксу**, у стилі Cutie (Cheng et al., 2023a): зчитування пам'яті на основі об'єктного запиту Cutie є категорично іншим механізмом (низхідне об'єктне представлення проти висхідного зіставлення на рівні пікселя/боксу), недоступним для замороженої, лише промπτованої поверхні втручання цього проекту, але його в принципі можна поєднати з конвеєром на основі SAM2 як зовнішній модуль повторної ідентифікації.
6. **Явне калібрування порогу на основі точності-повноти проти відомої базової частоти позитивного класу $\sim 10\%$** , дотримуючись підходу Saito and Rehmsmeier (2015): пороги тригера цього проекту були налаштовані шляхом максимізації J&F на попередньо відібраній за істинною розміткою підмножині істинно позитивних випадків — неявно за базової частоти 100% — ніколи проти робочої точки точність/повнота, обчисленої на справжній базовій частоті $\sim 10\%$ повної популяції. Поріг, явно обраний для утримання точності тригера вище цільового рівня на невідібраній популяції, не був випробуваний.
7. **Довгострокова, багаторівнева консолідація пам'яті як альтернатива повторному промптингу**, у стилі XMem (Cheng and Schwing, 2022): замість виявлення дрейфу та повторного закріплення через свіжий промπτ-бокс, підтримувати консолідований банк довготривалої пам'яті, за своєю суттю більш стійкий до пошкодження одним кадром, звертаючись до кореневої причини (втрата справжнього якоря через переповнення буфера), а не реагуючи на її симптом — хоча це вимагає архітектурного доступу, якого дизайн замороженого чекпоінта цього проекту не використовує.

8. Висновок

Заморожена SAM2.1 Hierarchical-Tiny, добре промπτована та оцінена на офіційному бенчмарку SA-V, отримує J&F = 72.1 на val і 74.4 на test взагалі без корекції. Механізм корекції дрейфу на основі моделі руху, розроблений для закриття задокументованого розриву у 58.2 пункти, відновлюваного еталонним прогнозом, досягає приросту 15.5 пункти на об'єктах, для яких він був побудований, але є чистою

шкодою — на 3.4 пункти нижче базової лінії — коли застосовується без відбору до повної, невідібраної популяції, на якій йому дійсно довелося б працювати при розгортанні. Дванадцять подальших спроб пом'якшення, що охоплюють гейтинг на рівні кадру, запобіжники на рівні об'єкта, попередній відбір на основі ознак та пом'якшення корекції, звужують цей розрив, не усуваючи його; найкращий результат у всій серії залишається на 0.8 пункти нижче базової лінії на val і на 1.8 пункти нижче на test. Ця найкраща конфігурація, D4, не є вирішально кращою за кілька близьких альтернатив — A2 (−1.0 п.п.) і D1@0.10 (−0.9 п.п.) перебувають у межах 0.1–0.2 п.п. від неї на val, розрив, ймовірно, у межах похибки вимірювання за відсутності будь-яких обчислених довірчих інтервалів (розділ 3.5), — тому важливим висновком є те, що жодна конфігурація в цій родині не усуває розрив до базової лінії, а не точне ранжування серед кількох найближчих. Ми читаємо це не як невдачу знайти правильний гіперпараметр, а як доказ того, що власна рамка проєкту правильна: саме специфічність тригера за базової частоти позитивного класу приблизно 10%, а не точність корекції на об'єктах, які її потребують, є обмежувальним фактором того, чи безпечно розгортати механізм корекції дрейфу без еталонного прогнозу на замороженій моделі сегментації відео. Практична рекомендація з цієї серії — розгортати `box_centroid` без корекції дрейфу; жодна з досліджених модифікацій не виправдовує додаткові витрати на інференс і складність механізму повторного промπτу зі свіжим боксом, з огляду на виміряні відкладені результати. Ширше кажучи, ми рекомендуємо, щоб будь-який механізм корекції без еталонного прогнозу повідомляв як точність на куратованій підмножині, так і чистий ефект на повній популяції, перш ніж вважатися валідованим для розгортання. Ми наводимо повну серію, включно з кожним закритим негативним напрямком, щоб конкретні речі, які не спрацювали — і, що важливіше, причини, чому вони не спрацювали, — були доступні кожному, хто спробує неперевірені напрямки з розділу 7.

Заява про доступність даних

SA-V (Segment Anything Video) — це набір даних, випущений Meta AI, і для завантаження потрібна реєстрація в Meta AI; він не поширюється повторно цією статтею. Деталі набору даних та процес реєстрації доступні за адресою <https://ai.meta.com/datasets/segment-anything-video/>. Весь код, що реалізує базові політики промптингу, механізм виявлення та корекції дрейфу P5, і всі дванадцять варіантів пом'якшення (A1, B1, A2, D1–D4, три варіанти попереднього відбору E1, перевірка розбіжності мультимасок, натхнення DAM4SAM, та F1), випускається разом із цією статтею за адресою <https://github.com/bmnedashkivskyi-ai/no-oracle-drift-correction> (архівний знімок: Zenodo, DOI <https://doi.org/10.5281/zenodo.22811949>), разом з файлами CSV з результатами на рівні об'єктів, що лежать в основі кожної таблиці розділу 4. Усі кількісні результати в цій статті були отримані офіційним оцінювачем SA-V (`sam2/sav_dataset/sav_evaluator.py`) та офіційним оцінювачем DAVIS (`davis2017-evaluation`), а не будь-якою власною чи заснованою на LLM процедурою оцінювання.

Заява з етики

Ця робота не передбачає досліджень за участю людей. Вона використовує загальнодоступний (з реєстраційним доступом) дослідницький бенчмарк SA-V для його призначеної мети — оцінювання сегментації об'єктів відео, та публічно випущений, заморожений чекпоінт моделі (SAM2.1). Жодного аналізу з ідентифікацією особи не проводилося; відео SA-V можуть зображати людей, але внесок цієї статті є методологічним висновком щодо сукупної та пооб'єктної точності сегментації механізму корекції дрейфу, а не будь-яким аналізом осіб, що з'являються на відеозаписах.

Заява про попередню реєстрацію

Це дослідження не проходило попередньої реєстрації (preregistration). Стандартні рекомендації щодо попередньої реєстрації (наприклад, розрізнення exploratory/confirmatory, на якому ґрунтується практика реєстрації типу OSF) не вимагають цього тут: робота не звітує про жодні конфірмаційні статистичні перевірки гіпотез (розділ 3.5), а експериментальна серія була ітеративною та дослідницькою за своєю побудовою — кожна з дванадцяти спроб пом'якшення (розділи 3.4–4.5) була мотивована виміряним результатом попередньої спроби, а не визначена заздалегідь до збору даних, а подальше дослідницьке розширення, згадане в розділі 7, продовжує той самий патерн, а не перевіряє окремо попередньо сформульовану гіпотезу. Читачам варто зважати на висновки статті відповідно: розрізнення між тим, що передбачалося, і тим, що було виявлено в процесі роботи, зберігається у власному хронологічному викладі результатів статті (розділи 3.4–4.5), а не через окремий зареєстрований протокол.

Розкриття інформації про використання ШІ

Написання цієї статті відбувалося за допомогою ШІ. Текст рукопису (включно з цим розділом) був складений агентом ШІ, що працював на основі набору наявних, перевірених людиною документів з експериментальними результатами, при цьому завдання написання було окреслене як точна транскрипція та організація цих результатів, а не проектування чи проведення експериментів. Основні експерименти — пошук базової політики промптингу, механізм корекції дрейфу P5 та його калібрування, а також усі дванадцять спроб пом'якшення — були розроблені та виконані під час емпіричного дослідницького проекту за участю агента ШІ, в якому агент ШІ висував гіпотези, реалізовував скрипти оцінювання та проводив експерименти проти офіційних оцінювачів SA-V і DAVIS під людським наглядом та ухваленням рішень у ключових точках розгалуження (наприклад, чи відкривати відкладене розбиття test, чи продовжувати напрямок F1 попри негативний пілот, чи продовжувати перевірку розбіжності мультимасок, натхненну DAM4SAM, як мотивовану літературою подальшу спробу). Ми заявляємо це прямо: як експериментальний процес, так і цей опис передбачали суттєву участь агента ШІ, і читачам слід враховувати це відповідно, поряд з тим фактом, що кожне наведене число простежується до запуску офіційного оцінювача на реальних

передбаченнях моделі, а не до будь-якої згенерованої чи оціненої III цифри.

Конфлікт інтересів

Автори заявляють про відсутність конфлікту інтересів.

Фінансування

Це дослідження не отримало жодного спеціального фінансування. Фінансування не заявлено.

Література

- Eric Arazo, Diego Ortego, Paul Albert, Noel E. O'Connor, and Kevin McGuinness. Pseudo-labeling and confirmation bias in deep semi-supervised learning, 2020. URL <https://arxiv.org/abs/1908.02983>. Published at IJCNN 2020.
- Ho Kei Cheng and Alexander G. Schwing. XMem: Long-term video object segmentation with an Atkinson-Shiffrin memory model, 2022. URL <https://arxiv.org/abs/2207.07115>. ECCV 2022.
- Ho Kei Cheng, Seoung Wug Oh, Brian Price, Joon-Young Lee, and Alexander Schwing. Putting the object back into video object segmentation, 2023a. URL <https://arxiv.org/abs/2310.12982>.
- Ho Kei Cheng, Seoung Wug Oh, Brian Price, Alexander Schwing, and Joon-Young Lee. Tracking anything with decoupled video segmentation, 2023b. URL <https://arxiv.org/abs/2309.03903>. ICCV 2023.
- Shuangrui Ding, Rui Qian, Xiaoyi Dong, Pan Zhang, Yuhang Zang, Yuhang Cao, Yuwei Guo, Dahua Lin, and Jiaqi Wang. SAM2Long: Enhancing SAM 2 for long video segmentation with a training-free memory tree, 2024. URL <https://arxiv.org/abs/2410.16268>. ICCV 2025.
- Jie Huang, Xinyun Chen, Swaroop Mishra, Huaixiu Steven Zheng, Adams Wei Yu, Xinying Song, and Denny Zhou. Large language models cannot self-correct reasoning yet, 2023. URL <https://arxiv.org/abs/2310.01798>. ICLR 2024.
- Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, Piotr Dollár, and Ross Girshick. Segment anything, 2023. URL <https://arxiv.org/abs/2304.02643>. ICCV 2023.
- Meta AI. SA-V dataset, 2024. URL <https://ai.meta.com/datasets/segment-anything-video/>.
- Seoung Wug Oh, Joon-Young Lee, Ning Xu, and Seon Joo Kim. Video object segmentation using space-time memory networks, 2019. URL <https://arxiv.org/abs/1904.00607>. ICCV 2019.

- Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos, 2024. URL <https://arxiv.org/abs/2408.00714>.
- Takaya Saito and Marc Rehmsmeier. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3):e0118432, 2015. doi: 10.1371/journal.pone.0118432. URL <https://doi.org/10.1371/journal.pone.0118432>.
- Jovana Videnovic, Alan Lukezic, and Matej Kristan. A distractor-aware memory for visual object tracking with SAM2, 2024. URL <https://arxiv.org/abs/2411.17576>. CVPR 2025.
- Paul Voigtlaender, Jonathon Luiten, Philip H. S. Torr, and Bastian Leibe. Siam R-CNN: Visual tracking by re-detection, 2020. URL <https://arxiv.org/abs/1911.12836>. CVPR 2020.
- Dequan Wang, Evan Shelhamer, Shaoteng Liu, Bruno Olshausen, and Trevor Darrell. Tent: Fully test-time adaptation by entropy minimization, 2020. URL <https://arxiv.org/abs/2006.10726>. ICLR 2021.
- Qin Wang, Olga Fink, Luc Van Gool, and Dengxin Dai. Continual test-time domain adaptation, 2022. URL <https://arxiv.org/abs/2203.13591>. CVPR 2022.
- Zheng Zhu, Qiang Wang, Bo Li, Wei Wu, Junjie Yan, and Weiming Hu. Distractor-aware Siamese networks for visual object tracking, 2018. URL <https://arxiv.org/abs/1808.06048>. ECCV 2018.